



Università di Padova

Corso di Ingegneria del Software · A.A. 2026/2027

Verbale Incontro con Eggon

Versione v1.0.0 · Ultima modifica: 2026-11-11

Data	2026-11-10
Ora inizio – Ora fine	16.50 – 17.30
Modalità	Google Meet
Stato	Approvato
Responsabile	Francesco Furin
Redattore	Alessandro Rasia dal Polo
Verificatore	Sara Stefani
Destinatari	Prof. Tullio Vardanega Prof. Riccardo Cardin Referenti aziendali (Eggon S.r.l.)

Registro delle modifiche

Versione	Data	Autore	Verificatore	Descrizione
1.0.0	2026-11-11	Francesco Furin	—	Approvazione per il rilascio
0.1.0	2026-11-10	Alessandro Rasia dal Polo	Sara Stefani	Stesura iniziale del verbale

Indice

1 Partecipanti 3
2 Ordine del giorno 3
3 Svolgimento della riunione 3
3.1 Canali di comunicazione e cadenza degli allineamenti periodici 3
3.2 Strategia di disaccoppiamento architetturale e interazione con i servizi NEXUM ... 4
3.3 Fornitura di documentazione, regolamenti e dati di collaudo 4
3.4 Accesso ai modelli linguistici su AWS Bedrock e gestione dei vincoli di budget 4
3.5 Selezione delle tecnologie per il database vettoriale e l'orchestrazione 4
3.6 Definizione del perimetro dei requisiti per la baseline RTB 5
3.7 Visione evolutiva a lungo termine del prodotto 5
3.8 Standard tecnologici: versioni di Ruby on Rails, gemma ruby_llm e framework Angular 5
3.9 Ingestione documentale, chunking e vettorizzazione della knowledge base 5
3.10 Progettazione dell'interfaccia utente (WebApp) e comportamento dell'agente 5
3.11 Gestione transazionale delle richieste concorrenti e sovrapposizione ferie 6
3.12 Analisi dei rischi: benchmark dei modelli e prevenzione della prompt injection 6
4 Conclusioni 6

1 Partecipanti

Nome Cognome	Ruolo / Ente	Presenza
Jatin Bajaj	RickandCommit	P
Dorde Blagojevic	RickandCommit	P
Nicola Bonetto	RickandCommit	P
Francesco Furin	RickandCommit	P
Luka Lacic	RickandCommit	P
Alessandro Rasia dal Polo	RickandCommit	P
Sara Stefani	RickandCommit	P
Referenti aziendali	Eggon S.r.l.	P

Legenda: P = Presente · A = Assente

2 Ordine del giorno

1. Definizione dei canali di comunicazione e della cadenza degli allineamenti periodici
2. Strategia di disaccoppiamento architetturale e interazione con i servizi NEXUM
3. Fornitura di documentazione, regolamenti e dati di collaudo
4. Accesso ai modelli linguistici su AWS Bedrock e gestione dei vincoli di budget
5. Selezione delle tecnologie per il database vettoriale e l'orchestrazione
6. Definizione del perimetro dei requisiti per la baseline RTB
7. Visione evolutiva a lungo termine del prodotto
8. Standard tecnologici: versioni di Ruby on Rails, gemma ruby_llm e framework Angular
9. Ingestione documentale, chunking e vettorizzazione della knowledge base
10. Progettazione dell'interfaccia utente (WebApp) e comportamento dell'agente
11. Gestione transazionale delle richieste concorrenti e sovrapposizione ferie
12. Analisi dei rischi: benchmark dei modelli e prevenzione della prompt injection

3 Svolgimento della riunione

3.1 Canali di comunicazione e cadenza degli allineamenti periodici

In apertura della riunione, il gruppo e i referenti aziendali hanno concordato l'organizzazione delle comunicazioni operative per la fase RTB:

- È stata stabilita una riunione settimanale ordinaria fissata ogni **martedì alle ore 17.00** in modalità telematica (Google Meet).
- Per le comunicazioni rapide, chiarimenti asincroni puntuali e condivisione di materiale operativo è stato creato un gruppo dedicato su **Telegram**.

3.2 Strategia di disaccoppiamento architetturale e interazione con i servizi NEXUM

Il gruppo ha domandato quali siano le modalità previste per interagire con i servizi NEXUM durante le fasi di sviluppo del Proof of Concept (PoC) e del Minimum Viable Product (MVP).

L'azienda ha raccomandato di sviluppare inizialmente un'architettura completamente autonoma e disaccoppiata rispetto all'infrastruttura di NEXUM. L'esperienza dei team dei precedenti anni accademici ha evidenziato come l'approccio più rapido ed efficace consista nel concentrarsi prioritariamente sul core business del progetto (la logica conversazionale dell'agente e l'elaborazione dei dati), tralasciando temporaneamente i dettagli di autenticazione e integrazione interna della piattaforma aziendale.

Solo a valle del consolidamento del PoC, qualora l'avanzamento lo consenta, si valuterà il porting e l'incorporamento all'interno di NEXUM. L'azienda metterà comunque a disposizione la documentazione tecnica e, se necessario, il codice sorgente di NEXUM per consultazione.

3.3 Fornitura di documentazione, regolamenti e dati di collaudo

In merito alla disponibilità di dati reali o sintetici per l'addestramento e il test della knowledge base, l'azienda ha chiarito che predisporrà un documento generale relativo alla disciplina contrattuale e al regolamento su ferie e permessi.

Il manuale utente di NEXUM verrà trasmesso direttamente tramite il canale Telegram di coordinamento. Inoltre, l'azienda sta predisponendo un insieme di API dedicate per la gestione delle richieste di ferie e permessi, concepite per simulare le transazioni durante la fase di PoC.

3.4 Accesso ai modelli linguistici su AWS Bedrock e gestione dei vincoli di budget

È stata confermata la concessione da parte di Eggon di un set di credenziali di accesso ad **Amazon Web Services (AWS) Bedrock**, che consentirà al gruppo di utilizzare i Large Language Model disponibili nel marketplace (quali Claude di Anthropic e altri modelli supportati).

I referenti hanno evidenziato che l'account AWS sarà soggetto a un budget economico prefissato: il gruppo dovrà monitorare il consumo dei token e i costi generati dalle invocazioni API durante le sessioni di sviluppo e test per prevenire il superamento del massimale.

3.5 Selezione delle tecnologie per il database vettoriale e l'orchestrazione

Il gruppo ha chiesto se sussistano vincoli o preferenze per l'implementazione del database vettoriale e del motore di orchestrazione RAG.

L'azienda ha indicato come preferibile l'impiego di tecnologie già consolidate internamente a Eggon, con particolare riferimento a **PostgreSQL con estensione pgvector**. Riguardo al framework di orchestrazione, il team gode di piena autonomia decisionale, potendo selezionare lo strumento ritenuto più idoneo alla complessità del problema.

3.6 Definizione del perimetro dei requisiti per la baseline RTB

È stato chiesto un chiarimento in merito alla portata dei requisiti descritti nel capitolato, per comprendere se essi costituiscano il traguardo dell'MVP o se rappresentino la base minima attesa già per la revisione RTB.

I referenti aziendali hanno chiarito che i requisiti specificati nel capitolato costituiscono già il perimetro minimo irriducibile per l'avanzamento in RTB.

3.7 Visione evolutiva a lungo termine del prodotto

Sulla visione di lungo termine, l'azienda auspica la convergenza del progetto verso una piena integrazione nei servizi NEXUM.

L'approccio strategico concordato si articola in due stadi:

1. **Fase 1 (PoC / RTB):** modellare il concierge come un **agent esterno autonomo** capace di soddisfare i requisiti e interfacciarsi con le API simulate o fornite da Eggon;
2. **Fase 2 (MVP / PB):** integrare l'agente all'interno dell'ecosistema NEXUM, abilitando l'accesso transazionale completo.

3.8 Standard tecnologici: versioni di Ruby on Rails, gemma ruby_llm e framework Angular

In merito alle compatibilità dei framework:

- **Ruby on Rails:** operando come componente disaccoppiato, non sussiste alcun obbligo di retrocompatibilità con le versioni legacy utilizzate internamente da NEXUM. È raccomandato l'utilizzo della versione stabile più recente (**latest version**).
- **Gemma ruby_llm:** è consigliato l'impiego della versione 2.1.1 (o successiva stabile), già testata con successo da Eggon, al fine di garantire trasparenza e coerenza architetturale.
- **Frontend:** la versione di riferimento aziendale è **Angular v18**.

3.9 Ingestione documentale, chunking e vettorizzazione della knowledge base

Riguardo al trattamento dei documenti aziendali, il gruppo ha domandato quali formati sia necessario supportare oltre al PDF.

L'azienda ha chiarito che i documenti da processare sono principalmente formati facilmente convertibili (PDF, testo strutturato). L'elemento di maggiore rilevanza tecnica non risiede nella gestione di molteplici estensioni, bensì nella progettazione della pipeline di ingestione: la corretta strategia di chunking, la qualità della vettorizzazione semantica e la gestione dell'accuratezza nel recupero delle informazioni (**retrieval**) costituiscono il valore centrale del modulo RAG.

3.10 Progettazione dell'interfaccia utente (WebApp) e comportamento dell'agente

È stato confermato che non è presente un'interfaccia grafica preesistente per il concierge: la WebApp di chat dovrà essere sviluppata da zero.

In merito al feedback visivo sul ragionamento del modello (**chain-of-thought / thought process**), l'azienda ha chiarito che tale funzionalità non è indispensabile ai fini della user

experience aziendale, in quanto molti agenti cifrano o aggregano tali passaggi interni. L'attenzione deve invece convergere sulla definizione di un **system prompt** rigoroso e su robusti meccanismi di **guardrails** a presidio dell'affidabilità delle risposte.

3.11 Gestione transazionale delle richieste concorrenti e sovrapposizione ferie

Il gruppo ha chiesto se eventuali sovrapposizioni temporali tra richieste di ferie/permessi debbano essere valutate e gestite dall'agente LLM.

L'azienda ha spiegato che il modulo dell'agente deve rimanere agnostico rispetto alle policy stringenti di business. Tali controlli di validità e sovrapposizione devono essere eseguiti in modo deterministico dal backend applicativo tramite le chiamate API, in quanto le regole contrattuali possono variare notevolmente a seconda dell'azienda cliente.

3.12 Analisi dei rischi: benchmark dei modelli e prevenzione della prompt injection

In chiusura, sono state discusse le principali difficoltà incontrate dai gruppi negli anni precedenti:

1. **Scelta e taratura del modello LLM:** Difficoltà nella scelta del modello giusto in base alle esigenze. La contromisura consiste nell'eseguire test e benchmark comparativi tra i diversi modelli disponibili su Bedrock;
2. **Sicurezza e Prompt Injection:** rischio di manipolazione del prompt o esfiltrazione accidentale di dati sensibili (PII). È prioritario progettare filtri di input/output rigorosi per garantire la conformità agli standard di sicurezza aziendale.

4 Conclusioni

L'incontro ha fornito al gruppo un quadro chiaro e operativo per l'avvio dello Sprint 1 di RTB: sono stati formalizzati i canali di comunicazione, definito il principio di disaccoppiamento architetturale (concierge come agente esterno autonomo), confermati gli standard tecnologici (PostgreSQL con pgvector, Rails latest, Angular 18) e pianificate le attività preliminari su AWS Bedrock e sicurezza.

Firma dell'azienda

Gianpaolo Ferrarin

Data: 2026-11-11